


Minimum Spanning Tree

Union-Find Disjoint Sets

- Union-Find Disjoint Set เป็นโครงสร้างข้อมูลที่จำลองกลุ่มของ set ที่ไม่มีตัวซ้ำกันที่มีประสิทธิภาพ ใช้เวลาประมาณ $O(1)$ ในการตัดสินใจว่า item สองตัวนั้นอยู่ใน set เดียวกันหรือไม่ และทำการรวม disjoint set สองอันเป็น set ที่ใหญ่ขึ้นได้อย่างรวดเร็ว
- โครงสร้างข้อมูลนี้สามารถถูกนำไปใช้ในปัญหาเกี่ยวกับการหา connected component ใน undirected graph
- เริ่มต้นแต่ละโหนดจะเป็น disjoint set แต่ละอัน หลังจากนั้นเราจะทำการรวมสองเส้นโหนดโดยใช้เส้นเชื่อม
- ดังนั้นเราสามารถทดสอบว่าสองโหนดอยู่ใน set เดียวกันได้ไม่ยาก

- Operation ที่ต้องการดังกล่าว ไม่ support จาก C++STL set เนื่องจากไม่ได้ออกแบบมาเพื่อการทำ disjoint set
- การใช้ vector ของ set และวนรอบแต่ละตัวเพื่อหาว่า set ไหนที่ item นั้นเป็นสมาชิกอยู่เสียค่าใช้จ่ายสูง C++STL set_union ไม่มีประสิทธิภาพเวลารวมสอง set ใช้ linear time
- ดังนั้นเราจึงต้องการโครงสร้างข้อมูลที่มีประสิทธิภาพ นั่นคือ Union-Find Disjoint Sets

- แนวคิดของโครงสร้างข้อมูลนี้คือการเลือกตัวแทน 'parent' item เป็นตัวแทนของ set
- ถ้าเราแน่ใจว่าแต่ละ set ถูกแทนด้วย item เพียงตัวเดียว แล้วการตัดสินใจถ้า item นั้นอยู่ใน set หรือไม่จะทำได้ง่ายเลย นั่นคือ เราใช้ตัวแทน 'parent' item ในการระบุ set เลย

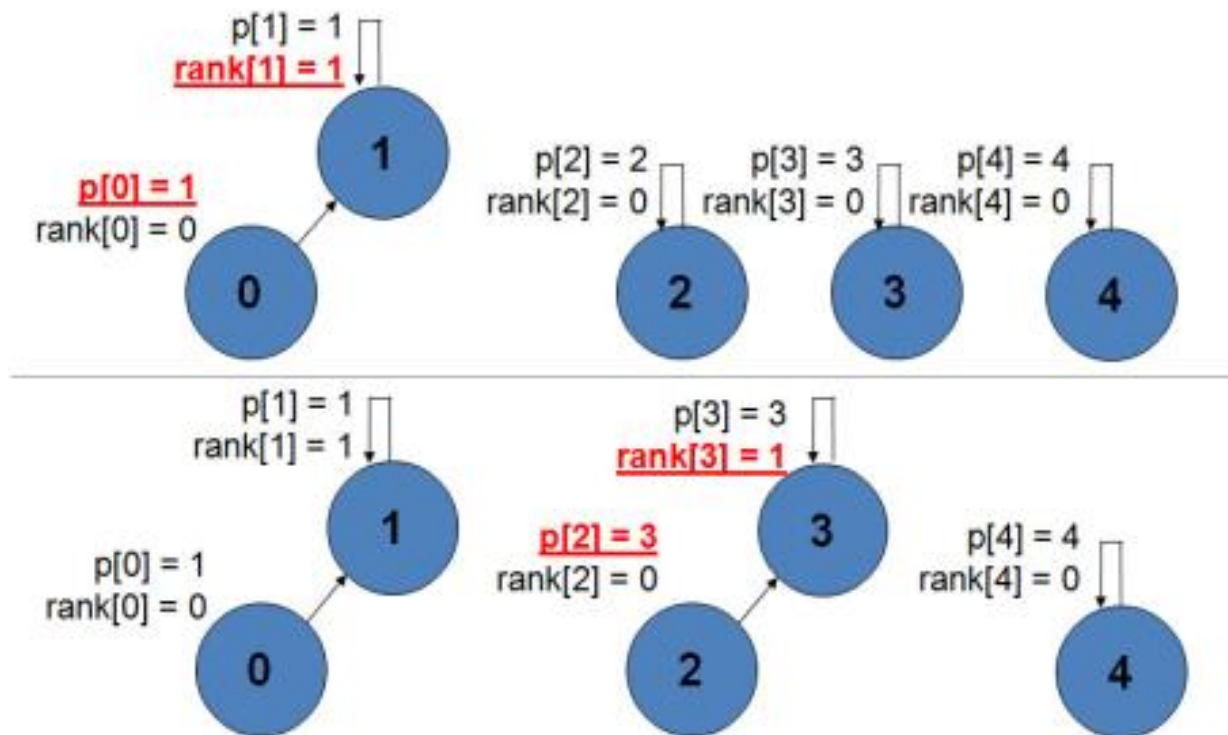


- ในการสร้าง Union-Find Disjoint Set จะสร้างโครงสร้าง tree ที่ disjoint sets นั้นอยู่ในรูปของต้นไม้หลายๆ ต้น (Forest of trees) โดยต้นไม้แต่ละต้นนั้นจะสอดคล้องกับ 1 disjoint set ทั้งนี้ root ของ tree จะถูกนำมาใช้เป็นตัวแทนของ set
- ดังนั้นตัวแทนที่เป็นตัวบ่งบอก set นั้นสามารถทำได้โดยท่องไปตามสายของ parent ไปยัง root ของ tree เนื่องจาก tree มีได้เพียง 1 root

- การจะทำให้มีประสิทธิภาพ เราจะเก็บ index ของ parent และความสูงของ tree ของแต่ละ set ไว้ (v_i p และ v_i rank ใน code ต่อไป) ทั้งนี้ v_i คือ vector of integer $p[i]$ เก็บ parent ของ item i
- ถ้า item i เป็นตัวแทนของ disjoint set แล้ว $p[i]=i$ นั่นคือ self-loop
- $rank[i]$ เก็บความสูงของ tree ที่มี root ที่ item i


- สมมติว่าเรามี 5 disjoint sets $\{0,1,2,3,4\}$ เริ่มต้นเราจะให้แต่ละ item เป็น disjoint set ด้วยตัวมันเองและให้ $\text{rank} = 0$ และ parent ของแต่ละตัวเป็นตัวมันเอง
- ในการรวมสอง disjoint set เราจะกำหนดตัวแทน $\text{item}(\text{root})$ จากหนึ่งใน 2 disjoint set ให้เป็น parent ใหม่ของอีก disjoint set การทำเช่นนี้ทำให้การรวม tree 2 ต้นใน Union-Find Disjoint Sets มีประสิทธิภาพ
- $\text{unionSet}(i,j)$ จะทำให้ทั้งสอง item i และ j มีตัวแทนตัวเดียวกันไม่ว่าทางตรงก็ทางอ้อม

- การทำให้มีประสิทธิภาพ เราจะใช้ข้อมูลใน vi rank เพื่อกำหนด ตัวแทน item ของตัวที่มี rank สูงกว่าให้เป็น parent ใหม่ของอีกตัวที่มี rank ต่ำกว่า เพื่อให้ rank ของ tree ที่ได้ต่ำที่สุด
- ถ้าทั้งคู่มี rank เท่ากัน เราจะเลือกมาสักตัวหนึ่งให้เป็น parent ใหม่และเพิ่มค่าของ root's rank ทำแบบนี้เรียกว่า union by rank




- รูปต่อไปเป็นตัวอย่าง $\text{unionSet}(0,1)$ โดยกำหนดให้ $p[0]$ เป็น 1 และ $rank[1]$ เป็น 1 และต่อไปเป็น $\text{unionSet}(2,3)$ โดยกำหนด $p[2] = 3$ และ $rank[3]=1$

- เราจะสมมติว่าฟังก์ชัน $\text{findSet}(i)$ จะเรียก $\text{findSet}(p[i])$ แบบ recursive เพื่อหาตัวแทนของ set
- ในรูปต่อไป มีการเรียก $\text{unionSet}(4,3)$ เรามี $\text{rank}[\text{findSet}(4)] = \text{rank}[4]=0$ ซึ่งน้อยกว่า $\text{rank}[\text{findSet}(3)] = \text{rank}[3]=1$
- ดังนั้นเมื่อเรากำหนด $p[4]=3$ โดยไม่เปลี่ยนแปลงความสูงของ tree
- นี่คือการทำงานของ union by rank



- ที่นี้หากต้องการตรวจสอบว่าอยู่ set เดียวกันหรือไม่ isSameSet(0,4) ทำงานได้โดยไปเรียกหาว่า findSet(0) และ findSet(4) เป็นตัวเดียวกันหรือไม่
- ตัวอย่างเช่น findSet(4) = findSet(p[4])= findSet(3)=3



- มีเทคนิคที่ทำให้เพิ่มความเร็วของการ findSet นั่นคือ path compression

```
#include <bits/stdc++.h>
using namespace std;
typedef vector<int> vi;

// Union-Find Disjoint Sets Library
// 1000 ปรึ่ได้
vi pset(1000), setSize(1000);
int _numDisjointSets;
void initSet(int N) {
    setSize.assign(N, 1);
    _numDisjointSets = N;
    pset.assign(N, 0);
    for (int i = 0; i < N; i++)
        pset[i] = i;
}
```

```

int findSet(int i) {
    return (pset[i] == i) ? i : (pset[i] = findSet(pset[i]));
}

bool isSameSet(int i, int j) {
    return findSet(i) == findSet(j);
}

void unionSet(int i, int j) {
    if (!isSameSet(i, j)) {
        _numDisjointSets--;
        setSize[findSet(j)] += setSize[findSet(i)];
        pset[findSet(i)] = findSet(j);
    }
}

int numDisjointSets() { return _numDisjointSets; }
int sizeOfSet(int i) { return setSize[findSet(i)]; }

```

```

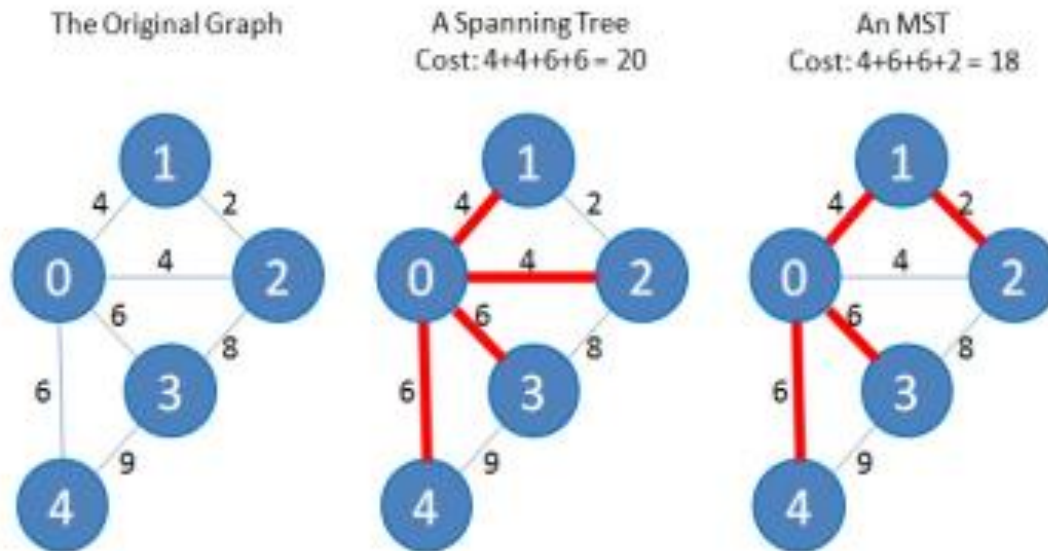
int main() {
    printf("Assume that there are 5 disjoint sets initially\n");
    initSet(5); // create 5 disjoint sets
    unionSet('A' - 'A', 'B' - 'A'); // unionSet(A, B)
    unionSet('A' - 'A', 'C' - 'A'); // unionSet(A, C)
    unionSet('D' - 'A', 'B' - 'A'); // unionSet(D, B)
    printf("findSet(A) = %d\n", findSet('A' - 'A'));
    // will return 2 (the parent ID of 'A', 'B', 'C', 'D')
    printf("findSet(B) = %d\n", findSet('B' - 'A'));
    // will return 2 (the parent ID of 'A', 'B', 'C', 'D')
    printf("findSet(C) = %d\n", findSet('C' - 'A'));
    // will return 2 (the parent ID of 'A', 'B', 'C', 'D')
    printf("findSet(D) = %d\n", findSet('D' - 'A'));
    // will return 2 (the parent ID of 'A', 'B', 'C', 'D')
    printf("findSet(E) = %d\n", findSet('E' - 'A'));
    // will return 4 (the parent ID of 'E')
    printf("isSameSet(A, E) = %d\n", isSameSet('A' - 'A', 'E' - 'A'));
    // will return 0 (false)
    printf("isSameSet(A, B) = %d\n", isSameSet('A' - 'A', 'B' - 'A'));
    // will return 1 (true)
    return 0;
}

```

<https://bit.ly/2HTYux1>

Minimum Spanning Tree

- กำหนดให้ กราฟแบบมีน้ำหนัก $G=(V,E)$ ที่ไม่มีทิศทางและเชื่อมกัน
- G เลือก subset ของเส้นเชื่อม E' ของ G ที่ทำให้กราฟ G ยังเชื่อมกันและน้ำหนักรวมของเส้นเชื่อมที่เลือก E' น้อยที่สุด



- ในการที่จะทำให้เงื่อนไขการเชื่อมกันสำเร็จนั้น เราต้องการอย่างน้อย $V-1$ เส้นเชื่อมเพื่อที่จะทำให้เกิดโครงสร้าง tree และ tree นี้จะต้องแผ่ทั่ว (span) ทุกโหนด V ใน G ถึงจะเป็น spanning tree
- มีหลาย spanning tree ใน G ทั้ง DFS และ BFS ก็สร้าง spanning tree ได้
- แต่ท่ามกลาง spanning tree ทั้งหมด จะมีบางต้น(อย่างน้อยหนึ่งต้น) ที่มีน้ำหนักรวมน้อยที่สุด

- ปัญหา Minimum Spanning Tree(MST) มีหลาย application
- ตัวอย่างเช่น เราสามารถจำลองปัญหาการสร้างถนนในเมืองที่ห่างไกลโดยใช้ MST ได้ โดยที่โหนดคือเมืองและเส้นเชื่อมคือถนนที่เราอาจจะสร้างเพื่อเชื่อมระหว่างเมืองสองเมือง ค่าใช้จ่ายในการสร้างถนนเพื่อเชื่อมเมือง i และเมือง j คือน้ำหนักของเส้นเชื่อม (i, j) MST ของกราฟนี้คือค่าใช้จ่ายต่ำสุดในการสร้างถนนเพื่อให้เชื่อมทุกเมือง
- MST สามารถแก้ได้ด้วยหลายๆ algorithm เช่น Prim's และ Kruskal's ทั้งคู่เป็น **Greedy algorithm**
- น้ำหนักของ MST ที่ได้จากสองอัลกอริทึมนั้นเป็นค่าเฉพาะนั้นคือ อาจมี MST หลายต้นแต่มีค่าน้ำหนักน้อยสุดค่าเดียว

Kruskal's Algorithm

- Joseph Bernard *Kruskal* Jr.'s algorithm เริ่มต้นจะเรียงเส้นเชื่อม E ตามน้ำหนักจากน้อยไปมาก สามารถทำได้ไม่ยากโดยการเก็บเส้นเชื่อมไว้ใน EdgeList data structure จากนั้น sort มันจากน้อยไปมาก Kruskal's algorithm จะลองเพิ่มเส้นเชื่อมเข้าไปใน MST ตราบเท่าที่การเพิ่มเส้นเชื่อมนั้นไม่ทำให้เกิด cycle
- ในการตรวจสอบ cycle นั้นทำได้โดยการใช้ Union-Find Disjoint Sets
- Code ค่อนข้างสั้นเพราะว่าเราแยกส่วน Union-Find Disjoint Sets ไปอีกฟังก์ชัน
- เวลาในการทำงานเป็น $O(\text{sorting} + \text{trying to add each edge} \times \text{cost of Union-Find operations}) = O(E \log E + E \times (\approx 1)) = O(E \log E) = O(E \log V^2)$
- $= O(2E \log V) = O(E \log V)$.

```
#include <bits/stdc++.h>
```

```
using namespace std;
```

```
typedef pair<int, int> ii;
```

```
typedef vector<int> vi;
```

```
typedef vector<ii> vii;
```

Union-Find Disjoint Sets

```
vi pset(1000), setSize(1000);
```

```
int _numDisjointSets;
```

```
void initSet(int N) { setSize.assign(N, 1); _numDisjointSets = N;
```

```
pset.assign(N, 0); for (int i = 0; i < N; i++) pset[i] = i; }
```

```
int findSet(int i) { return (pset[i] == i) ? i : (pset[i] =  
findSet(pset[i])); }
```

```
bool isSameSet(int i, int j) { return findSet(i) == findSet(j); }
```

```
void unionSet(int i, int j) {
```

```
    if (!isSameSet(i, j)) {
```

```
        _numDisjointSets--;
```

```
        setSize[findSet(j)] += setSize[findSet(i)];
```

```
        pset[findSet(i)] = findSet(j); } }
```

```
int numDisjointSets() { return _numDisjointSets; }
```

```
int sizeOfSet(int i) { return setSize[findSet(i)]; }
```

```

vector<vii> AdjList;
vi taken;           // global boolean flag to avoid cycle
int main() {
    int V, E, u, v, w;
    scanf("%d %d", &V, &E);
    AdjList.assign(V, vii());
    vector< pair<int, ii> > EdgeList;
    // format: weight, two vertices of the edge
    for (int i = 0; i < E; i++) {
        scanf("%d %d %d", &u, &v, &w);    // read the triple: (a, b, w)
        EdgeList.push_back(make_pair(w, ii(u, v)));
    // but store it as: (w, a, b)
        AdjList[u].push_back(ii(v, w));
        AdjList[v].push_back(ii(u, w));
    }
    sort(EdgeList.begin(), EdgeList.end());
    // sort by edge weight in  $O(E \log E)$ 

```

```


int mst_cost = 0; initSet(V); // all V are disjoint sets initially
for (int i = 0; i < E; i++) { // for each edge, O(E)
    pair<int, ii> front = EdgeList[i];
    if (!isSameSet(front.second.first, front.second.second)) {
// if no cycle
        mst_cost += front.first;    // add the weight of e to MST
        unionSet(front.second.first, front.second.second);
// link endpoints
    }
} // note: the runtime cost of UFDS is very light
// note: the number of disjoint sets must eventually be one for a
valid MST
printf("MST cost = %d (Kruskal's)\n", mst_cost);

return 0;
}


```

<https://bit.ly/2WuBk4t>


Connect 1 and 2
As this edge is smallest




Connect 1 and 0
No cycle is formed




Cannot connect 0 and 2
As it will form a cycle.



Connect 0 and 3
The next smallest edge



Connect 0 and 4
MST is formed...



5 7

0 1 4

0 2 4

0 3 6

0 4 6


1 2 2

2 3 8

3 4 9

Prim's Algorithm

- Robert Clay Prim's algorithm นั้นเริ่มต้นเลือก start node มา (เพื่อความง่ายเราก็เลือกโหนด 0)



- หลังจากนั้น set ค่ามันว่าถูกใช้แล้ว (taken) และ enqueue ข้อมูลน้ำหนัก w และจุดปลายอีกฝั่ง u ของเส้นเชื่อม $0 \rightarrow u$ ที่ยังไม่ถูก taken ลงใน priority queue

- ข้อมูลคู่นี้ถูกเรียงใน priority queue ตามน้ำหนักที่เพิ่มขึ้น และถ้าน้ำหนักเท่ากันเรียงตามหมายเลข node
- หลังจากนั้น Prim's algorithm จะเลือก pair(w, u) แบบ greedy จาก priority queue โดยเลือกจากน้ำหนัก w ที่น้อยก่อน ถ้าจุดปลายของเส้นเชื่อมนี้ไม่เคยถูกพบมาก่อน การทำเช่นนี้เพื่อป้องกันการเกิด cycle

- ถ้า $\text{pair}(w,u)$ นั้นผ่านเงื่อนไข เราจะเพิ่ม น้ำหนักของ w ให้กับค่าของ MST และ u จะถูกมาร์คว่า taken และคู่ของ (w',v) ของแต่ละเส้นเชื่อม $u \rightarrow v$ ที่มีน้ำหนัก w' ที่เกิดกับ u ถูกเพิ่มลงไป priority queue ถ้า v ไม่เคย taken มาก่อน
- จะวนรอบทำไปจนกระทั่ง priority queue ว่าง
- code ยาวพอๆ กับ Kruskal และทำงานใน $O(\text{แต่ละเส้นเชื่อมทำงานครั้งเดียว} \times \text{ค่าใช้จ่ายในการ dequeue/enqueue}) = O(E \log E) = O(E \log V)$

```

#include <bits/stdc++.h>
using namespace std;
typedef pair<int, int> ii;
typedef vector<int> vi;
typedef vector<ii> vii;
vector<vii> AdjList;
vi taken;           // global boolean flag to avoid cycle
priority_queue<ii> pq; // priority queue to help choose shorter edges
void process(int vtx) {
    taken[vtx] = 1;
    for (int j = 0; j < AdjList[vtx].size(); j++) {
        ii v = AdjList[vtx][j];
        if (!taken[v.first]) pq.push(ii(-v.second, -v.first));
    }
}
// sort by (inc) weight then by (inc) id by using -ve sign to reverse
order

```

```

int main() {
    int V, E, u, v, w;
    scanf("%d %d", &V, &E);
    AdjList.assign(V, vii());
    vector< pair<int, ii> > EdgeList;
    //format: weight, two vertices of the edge

    for (int i = 0; i < E; i++) {
        scanf("%d %d %d", &u, &v, &w);
        // read the triple: (a, b, w)
        EdgeList.push_back(make_pair(w, ii(u, v)));
        // but store it as: (w, a, b)
        AdjList[u].push_back(ii(v, w));
        AdjList[v].push_back(ii(u, w));
    }
}

```


```

int mst_cost = 0;
// inside int main() --- assume the graph has been stored in AdjList
taken.assign(V, 0);
process(0);    //take vertex 0 and process all edges incident to vertex 0
mst_cost = 0;
while (!pq.empty()) { //repeat until V vertices (E = V-1 edges) are taken
    ii front = pq.top();
    pq.pop();
    u = -front.second;
    w = -front.first;    // negate the id and weight again
    if (!taken[u]){      // we have not connect this vertex yet
        mst_cost += w;
        process(u);
    }    // take u and process all edges incident to u
}    // each edge is in pq only once!
printf("MST cost = %d (Prim's)\n", mst_cost);
}


```

<https://bit.ly/2HWWXXc>


The original graph,
start from vertex 0




Connect 0 and 1
As this edge is smallest




Connect 1 and 2
As this edge is smallest



Connect 0 and 3
As this edge is smallest



Connect 0 and 4
MST is formed



ตัวอย่างของกราฟ

5 7

0 1 4

0 2 4

0 3 6

0 4 6

1 2 2

2 3 8

3 4 9